



Introdução a Análise e Visualização de Dados com Python

Prof. D.Sc. Ana Luiza Martins Karl,
Daniel Correa da Silva e Felipe Rimes Ferreira Casais

Conteúdo Programático

01

Introdução à
ciência de dados

02

Bibliotecas de
análise de dados

03

Tratamento e
preparação de dados

04

Visualização de
dados e storytelling



01

Introdução a ciência de dados

O que é ciência de dados?

A **ciência de dados** é uma área interdisciplinar que estuda grandes volumes de informações para extrair **informações**, **padrões** e **respostas** a perguntas complexas.

Ela se baseia em três pilares fundamentais:



Matemática & Estatística

Desenvolvimento de modelos preditivos, testes de hipóteses e estruturação de algoritmos complexos.



Computação & Programação

Processamento automatizado, engenharia de dados e análise computacional em larga escala.



Conhecimento de Negócios

Entendimento do problema real no contexto empresarial para gerar valor e impacto prático.

Por que estudar dados?




+90x

Explosão de Dados

O volume global de informações geradas saltou de 2 para 181 zettabytes em 15 anos.

Estudar dados é a chave para transformar esse caos em inteligência estratégica.

Volume de Dados Gerados Globalmente



Por que estudar dados?



Mercado aquecido

Empresas de todos os portes precisam de quem saiba lidar com grandes volumes de informação.



Boa remuneração

É uma das carreiras mais valorizadas e bem pagas no setor de tecnologia atualmente.



Poder de decisão

Você ajuda negócios a cortar custos, criar produtos melhores e prever tendências de consumo.



Flexibilidade

Permite atuação remota e em diversos setores, como saúde, finanças, serviços e varejo.

A qualidade dos dados é a base de qualquer sistema de IA

"Lixo entra, lixo sai"
(*garbage in, garbage out*)




O ciclo de vida de dados

Artigo 5º da LGPD



Nota: O ciclo acima representa o fluxo sequencial de tratamento de dados pessoais conforme as diretrizes e salvaguardas estabelecidas pela Lei Geral de Proteção de Dados (LGPD).



O ciclo de vida de dados



O ciclo de vida de dados



02

Estadística descriptiva

Estatística descritiva



Organização

É o ramo focado em organizar, resumir e apresentar conjuntos de dados de forma clara.



Ferramentas

Utiliza tabelas, gráficos e medidas numéricas para descrever características de uma amostra, sem fazer previsões.




Fundação

A estatística descritiva serve como uma das bases essenciais para toda a ciência de dados.

População e amostra


População: o conjunto completo de pessoas ou coisas de interesse.



Amostra: um subgrupo retirado da população pra representação



População e amostra



População: o conjunto completo de pessoas ou coisas de interesse.

Amostra: um subgrupo retirado da população para representação.

Variável: o dado ou a qualidade que você deseja medir no grupo pesquisado.



População e amostra

Exemplo:

- **População** – todos os alunos da UENF
- **Amostra** – 20 alunos de cada curso, sendo 10 alunos de cada gênero
- **Variáveis** – gênero, curso, CR, etc.

 A amostra precisa ser representativa da população, para que generalizações possam ser feitas

Importante:

Censo

Quando todos os elementos da população são analisados, temos um censo.

Ex: Censo do IBGE



Amostragem

Quando apenas parte da população é utilizada nas análises, ocorre um processo de amostragem

Ex: Pesquisa eleitoral



Tipos de variáveis

Variáveis

Quantitativas

Valores numéricos associados a contagens ou medições.

Discretos: resultam de contagens. Pertecem ao conjunto dos inteiros ($\mathbb{Z}$)

Contínuos – Podem assumir qualquer valor dentro dos números reais ($\mathbb{R}$)

Qualitativas

Características, categorias ou atributos, e não quantidades numéricas

Nominais – categorias sem qualquer relação de ordem entre si

Ordinais: categorias que possuem ordem entre si

Tipos de variáveis

As variáveis podem ser classificadas com relação a causa e efeito em um estudo:

Variáveis independentes

É a **causa** – o fator que você muda ou controla (muitas vezes chamada de entrada ou x);

Não depende de outras medidas;

Ex: o número de horas trabalhadas

Variáveis dependentes

É o **efeito** – resultado que você mede e que muda de acordo com outra variável (a saída ou y);

Seu valor muda por causa da variável independente.

Ex: O salário que você recebe no fim.

Medidas de tendência central

Usamos as medidas de tendência central para resumir um grande conjunto de números em um único valor representativo.



Servem para encontrar o “centro” ou o ponto de equilíbrio dos dados, facilitando a compreensão de pesquisas, comparações e a tomada de decisões.

Medidas de tendência central

Média aritmética: obtida pela soma de todos os valores dividida pela quantidade de elementos.

Aluno	Nota
Ana	9,8
Carlos	7,9
Jeferson	8,1
Maria	5,4
Paula	7,9
Thomaz	6,3

$$\frac{9,8 + 7,9 + 7,9 + 8,1 + 5,4 + 6,3}{6} = \frac{45,4}{6} = 7,5$$

Logo, a média é 7,5.

A média considera todos os valores, mas é sensível a extremos (*outliers*)

Medidas de tendência central

Mediana: corresponde ao valor central de um conjunto ordenado.

Aluno	Nota
Ana	9,8
Carlos	7,9
Jeferson	8,1
Maria	5,4
Paula	7,9
Thomaz	6,3

Sequência ordenada: 9,8; 8,1; **7,9; 7,9**; 6,3; 5,4

Logo, a mediana é 7,9.

- Em um conjunto com número par de elementos: média dos valores centrais.
- Em um conjunto com número ímpar de elementos: valor central.

A mediana é menos sensível a valores extremos, o que a torna muito útil quando há *outliers* presentes.

Medidas de tendência central

Moda: Valor que aparece com maior frequência.

Aluno	Nota
Ana	9,8
Carlos	7,9
Jeferson	8,1
Maria	5,4
Paula	7,9
Thomaz	6,3

Sequência ordenada: 9,8; 8,1; **7,9; 7,9**; 6,3; 5,4

Logo, a moda é 7,9

A moda é especialmente útil em dados categóricos e análises de frequência.

Medidas de dispersão

Para analisar o comportamento dos dados com relação as medidas de tendência central, utilizamos as medidas de dispersão.

As medidas de dispersão dão informações sobre:

- **Confiabilidade da média:** dizem se a média representa bem o grupo todo.
- **Grau de variação:** medem a distância dos valores até o centro.
- **Homogeneidade:** Mostram se os dados são parecidos ou muito diferentes.
- **Detecção de outliers:** Ajudam a achar erros ou valores estranhos nos dados.

Medidas de dispersão

Dois conjuntos de dados podem ter a mesma média, e ainda sim, se comportar de maneiras diferentes:

Conjunto A: {8, 8, 8, 8, 8};

Conjunto B: {2, 5, 8, 11, 14}

As principais medidas de dispersão são:

- **Amplitude:** Diferença entre o maior e o menor valor.
- **Variancia:** média do quadrado da distância até a média.
- **Desvio padrão:** raiz da variância na mesma unidade dos dados.
- **Coeficiente de variação:** Medida em porcentagem para comparar grupos.

Medidas de dispersão

Amplitude: diferença entre o maior e o menor valor.

Aluno	Nota
Ana	9,8
Carlos	7,9
Jeferson	8,1
Maria	5,4
Paula	7,9
Thomaz	6,3

Maior valor: 9,8; Menor valor: 5,4

Logo, a amplitude é $9,8 - 5,4 = 4,4$.

Simples de calcular, mas só considera os valores extremos.

Medidas de dispersão

Variância: Mede o grau de dispersão em relação à média.

Para amostra:

$$s^2 = \frac{\sum (\text{valor-média})^2}{n - 1}$$

Para população:

$$\text{Var} = \frac{\sum (\text{valor-média})^2}{n}$$

Medidas de dispersão

Variância: Mede o grau de dispersão em relação à média.

Aluno	Nota
Ana	9,8
Carlos	7,9
Jeferson	8,1
Maria	5,4
Paula	7,9
Thomaz	6,3

$$\text{Média} = 7,5667$$

$$s = [(9,8 - 7,5667)^2 + (8,1 - 7,5667)^2 + (7,9 - 7,5667)^2 + (7,9 - 7,5667)^2 + (6,3 - 7,5667)^2 + (5,4 - 7,5667)^2] / (6 - 1)$$

$$s = [4,9876 + 0,2844 + 0,1111 + 0,1111 + 1,6044 + 4,6944] / 5 = 11,793 / 5 = \mathbf{2,3586}$$

$$\text{Variancia} = s = \mathbf{2,3586}$$

Medidas de dispersão

Desvio padrão: Permite interpretar a variabilidade na mesma unidade dos valores originais, e por isso é uma das medidas mais utilizadas em Ciência de Dados.

$$\text{Desvio padrão} = \sqrt{\text{variância}}$$

- **Desvio padrão baixo:** dados mais homogêneos, próximos da média.
- **Desvio padrão alto:** maior variabilidade, maior dispersão.

O desvio padrão é essencial em análise exploratória, detecção de anomalias, normalização de dados e construção de modelos de aprendizagem de máquina.

Medidas de dispersão

Desvio padrão: Permite interpretar a variabilidade na mesma unidade dos valores originais, e por isso é uma das medidas mais utilizadas em Ciência de Dados.

Aluno	Nota
Ana	9,8
Carlos	7,9
Jeferson	8,1
Maria	5,4
Paula	7,9
Thomaz	6,3

$$\text{Média} = 7,5667$$

$$s = [(9,8 - 7,5667)^2 + (8,1 - 7,5667)^2 + (7,9 - 7,5667)^2 + (7,9 - 7,5667)^2 + (6,3 - 7,5667)^2 + (5,4 - 7,5667)^2] / (6 - 1)$$

$$s = [4,9876 + 0,2844 + 0,1111 + 0,1111 + 1,6044 + 4,6944] / 5 = 11,793 / 5 = 2,3586$$

$$\text{Variancia} = s = 2,3586$$
$$\text{Desvio padrão} = \sqrt{2,3586} = 1,54$$



02

Bibliotecas de análise de dados

Principais bibliotecas de análise de dados

Pandas

A biblioteca mais fundamental para manipulação e análise de dados. Fornece estruturas de dados rápidas e flexíveis, como as **DataFrames**, permitindo limpar, filtrar e agrupar dados de forma extremamente eficiente.

NumPy

Base da computação científica em Python. Introduz arrays multidimensionais poderosos (**ndarrays**) e funções matemáticas otimizadas, oferecendo alta performance no processamento de matrizes de dados.

Matplotlib & Seaborn

Essenciais para visualização. O Matplotlib oferece total controle sobre gráficos, enquanto o Seaborn simplifica a criação de visualizações estatísticas complexas e esteticamente atraentes sobre os DataFrames.

Ambientes e plataformas de desenvolvimento

Jupyter Notebook

A ferramenta padrão para experimentação científica. Permite alternar entre blocos de código executáveis, textos explicativos e visualizações ricas em uma interface **iterativa e dinâmica**.

VS Code

O editor mais popular da indústria. Com a extensão Python oficial, integra **ambiente interativo do Jupyter**, controle de versão, depuração avançada e autocompletar inteligente com Copilot.

Google Colab

A plataforma baseada em nuvem mais acessível. Permite rodar análises diretamente no navegador com **acesso gratuito a GPUs**, ideal para treinamentos pesados e compartilhamento rápido de relatórios.



03

Análise Exploratória de dados (EDA)



Organização dos dados

O Impacto da Desorganização

Dados desorganizados dificultam suas análises:

- Aumentam a ocorrência de erros;
- Dificultam a extração de informações;
- Comprometem o desempenho de modelos.

Na maioria das aplicações de ciência de dados, os conjuntos de dados são tratados de maneira tabular.

Estruturas de Dados

Os dados podem ser organizados de diferentes formas:

1. Estruturados

Organizados em linhas e colunas, seguindo um formato bem definido.

Ex: Planilhas, tabelas SQL, arquivos CSV, etc.

2. Semi-Estruturados

Possuem alguma organização, mas não seguem um modelo rígido.

Ex: JSON, XML, registros de APIs, etc.


3. Não Estruturados

Não possuem nenhuma organização tabular fixa.

Ex: Imagens, vídeos, áudios, textos livres, etc.

Organização dos dados

Na maioria das aplicações, os conjuntos de dados são tratados de maneira tabular:



Tribunal	Student	Project	Score
01	Sofía Hill	"Mars is red"	0.5/4
02	James Holmes	"Saturn has rings"	2.2/4
03	Marina Ortiz	"We live in Earth"	0.3/4
04	Paul Grant	"Neptune is blue"	1.0/4
05	Hanna Great	"Mercury is small"	3.8/4

Análise Exploratória dos Dados (EDA)

Antes da construção de qualquer modelo ou da extração de informações, é necessário entender as características essenciais dos dados.

O que devemos analisar?

01

Como estão organizados

02

Quais os padrões apresentam

03

Se existem inconsistências

04

Valores ausentes

05

Outliers, etc.

A EDA é essencial para verificar a qualidade dos dados

01

Identificação de inconsistências

02

Detecção de *outliers*

03

Detecção de valores ausentes

04

Entendimento da distribuição dos dados

05

Entendimento da variabilidade dos dados

06

Identificação de padrões

Detecção de inconsistências nos dados

Dados inconsistentes são informações que apresentam contradições lógicas, erros de digitação, conflitos entre fontes diferentes ou valores impossíveis no mundo real.

01

Valores Impossíveis

Idade negativa ou uma pessoa com 200 anos de idade.

02

Formatos Distintos

O mesmo campo preenchido de formas diferentes (ex: RJ e Rio de Janeiro).

03

Lógica Conflitante

Paciente com óbito registrado em 2019 e entrada na urgência em 2022.

04

Fontes Divergentes

Inconsistência de informações provenientes de bases de dados diferentes.

Detecção de *outliers*

Valores discrepantes, os *outliers*, são observações muito diferentes da maioria dos dados.

Exemplo prático de série numérica: 7, 8, 8, 9, **50**

Por que os outliers surgem? Principais motivos:

Erro de Digitação

Inserção incorreta de dados de forma manual no sistema.

Falhas em Sensores

Anomalias físicas ou mau funcionamento de dispositivos de medição.

Coleta de Dados

Problemas e inconsistências operacionais durante a extração.

Comportamentos Raros

Ações ou registros genuínos, mas fora da curva padrão esperada.

Eventos Excepcionais

Acontecimentos atípicos externos que impactam as métricas coletadas.

Detecção de valores ausentes

Valores ausentes ocorrem quando nenhuma informação é armazenada para um atributo em uma observação, podendo enviesar análises e comprometer modelos preditivos.

01

Omissão na Coleta

Campos ignorados ou não preenchidos pelos usuários durante o cadastro ou entrevista.

02

Falhas de Integração

Perda de dados no processo de transferência entre sistemas ou bases de dados distintas.

03

Atributo Inaplicável

Dados que legitimamente não se aplicam a certo registro (ex: nome do cônjuge quando o estado civil é solteiro).

04

Erros de Processamento

Falhas de conversão que resultam na deleção accidental de registros ou colunas.

Entendimento da distribuição dos dados

Compreender como os dados se espalham é o passo fundamental para escolher os modelos estatísticos corretos e extrair informações confiáveis sobre o comportamento sobre o problema.

01

Por que é importante?

Permite identificar a simetria dos dados, detectar anomalias e validar premissas cruciais para algoritmos de *machine learning*.

02

Como observar: **Histogramas**

Histogramas são utilizados para mapear a frequência dos dados em intervalos contínuos, revelando o formato da distribuição imediatamente.

03

Como observar: **Boxplots**

Boxplots são excelentes para visualizar a dispersão, a mediana, os quartis e destacar graficamente a presença de potenciais valores discrepantes.

04

Curvas de Densidade (KDE)

Suaviza o histograma para estimar a função de densidade de probabilidade, facilitando a identificação de picos múltiplos (bimodalidade).

Entendimento da variabilidade dos dados

Analisar a dispersão dos dados permite quantificar o quão distantes as observações estão do centro, revelando a consistência, a incerteza e a confiabilidade das informações.

01

Amplitude Total

A diferença direta entre o maior e o menor valor do conjunto de dados. É simples de calcular, mas extremamente sensível a valores extremos (*outliers*).

02

Variância

Mede o quão distantes os dados estão da média aritmética. Indica a dispersão geral em unidades quadráticas, servindo de base para modelos de inferência.

03

Desvio Padrão

A raiz quadrada da variância, que retorna a métrica de dispersão para a mesma unidade dos dados originais, facilitando a interpretação direta do comportamento.

04

Intervalo Interquartil (IQR)

Focado nos 50% centrais dos dados (Q3 - Q1). É uma medida robusta que ignora os extremos e resiste totalmente à distorção por anomalias.

Identificação de padrões

Mapear regularidades e comportamentos repetitivos nos conjuntos de dados é essencial para segmentar perfis, prever tendências e automatizar decisões inteligentes no negócio.

01

Análise de *Clusters* (agrupamento)

Agrupa registros semelhantes automaticamente, permitindo descobrir segmentos naturais dos dados sem regras pré-definidas.

02

Regras de Associação

Identifica afinidades e relações de ocorrência simultânea entre itens. Muito utilizada para estruturar sistemas de recomendação e *cross-selling*.

03

Séries Temporais

Avalia o comportamento dos dados ao longo do tempo para extrair componentes de sazonalidade, tendências de crescimento e ciclos repetitivos.

04

Reconhecimento de Formas

Emprega algoritmos para classificar e mapear estruturas complexas nos dados de entrada, fundamentando a análise preditiva moderna.

Representação gráfica dos dados

A tradução de dados em elementos visuais facilita a interpretação rápida e suporta análises exploratórias eficientes, permitindo identificar tendências, padrões, distribuições e anomalias latentes.

01 Distribuição Geral

QUANTITATIVO

Visualiza como variáveis numéricas se espalham continuamente.

- **Recomendado:** Histograma

02 Discrepâncias

QUANTITATIVO

Identifica *outliers* e resume a dispersão do conjunto.

- **Recomendado:** Boxplot

03 Comparação

QUALITATIVO

Avalia e contrasta a frequência de diferentes categorias.

- **Recomendado:** Gráfico de Barras

04 Proporções do Todo

QUALITATIVO (POUCOS GRUPOS)

Exibe a relação percentual de partes em relação a um total.

- **Recomendado:** Gráfico de Pizza

05 Tendência Temporal

TEMPORAL

Mapeia a evolução das observações ao longo do tempo.

- **Recomendado:** Gráfico de Linhas



04

Visualização de dados

Representação gráfica dos dados

A tradução de dados em elementos visuais facilita a interpretação rápida das informações. Os gráficos ajudam a:

01

Identificar tendências

Direcionamento histórico e comportamento dos dados no tempo.

02

Comparar categorias

Contraste de frequências e volumes entre diferentes grupos.

03

Visualizar distribuições

Mapeamento da dispersão e concentração de variáveis.

04

Detectar padrões

Identificação de correlações e recorrências nos dados.

05

Localizar anomalias


Destaque imediato de discrepâncias e outliers ocultos.

Histograma

Usado para representar a distribuição de dados numéricos.

Quando usar

Para entender o padrão de distribuição de uma variável.



Boxplot

Usado para representar a distribuição de dados numéricos.

Quando usar

Para detectar outliers e comparar a dispersão entre grupos.




Gráfico de barras

Usado para comparar valores entre categorias.

Quando usar

Para comparar grupos distintos e destacar discrepâncias.




Gráfico de linhas

Usado para comunicar tendências, variações e a direção geral de dados contínuos ao longo do tempo.

Quando usar

Séries temporais e tendências.





Gráfico de pizza

Usado para comunicar proporções de forma rápida e visual.

Quando usar

Exibir proporções, apresentar porcentagens ou resumir categorias.

Gráfico de Pizza — Sistemas Operacionais



Resumo

Objetivo	Tipo de dado	Gráfico recomendado
Ver a distribuição de uma variável numérica	Quantitativo	Histograma
Identificar <i>outliers</i> e resumir distribuição	Quantitativo	Boxplot
Comparar categorias	Qualitativo	Barras
Mostrar proporções percentuais	Qualitativo (poucos)	Pizza
Acompanhar evolução ao longo do tempo	Temporal	Linhas



05

***Storytelling* e decisões baseadas em dados**

Como comunicar as informações

"Depois de analisar e visualizar os dados, como eu transformo isso em uma mensagem que outra pessoa consiga entender?"

Análise de dados → Visualização → **Storytelling** → Decisão

Dados

"Temos 10.000 registros."

Informação

"A categoria A representa 42% dos registros."

Insight ✨

"A categoria A cresceu 35% nos últimos três meses e é o principal fator associado ao aumento observado."

O Foco Real

O objetivo da análise de dados não é produzir gráficos. É transformar dados em **evidências** que nos permitam compreender e comunicar alguma coisa.

O Desafio

A análise estatística pode estar perfeita, com um gráfico impecável, e ainda assim **não conseguir comunicar** o resultado final de forma clara.

Estrutura Narrativa com Dados

Como conectar padrões visuais e gráficos à construção de uma história persuasiva

01

O Gráfico

Identifica os **padrões e desvios** visuais na informação líquida.



02

A Jornada

Transforma dados estruturados em uma **sequência lógica** de fatos.



03


O Storytelling

Gera **contexto e ação** sobre a evidência analisada.

Um gráfico sozinho não é storytelling. A narrativa de dados conecta a rigidez estatística à necessidade humana de extrair significado e tomar decisões.





Estrutura Narrativa com Dados

A jornada lógica para transformar dados brutos em tomadas de decisão estratégicas



Um gráfico sozinho não é storytelling. A narrativa de dados conecta a rigidez estatística à necessidade humana de extrair significado e tomar decisões.

Bibliografia recomendada



Livros básicos, teórico-práticos, de baixo custo: R\$60 – R\$120,00

mãos na massa



Acesse: <https://encurtador.com.br/oaiA>



Obrigada!

@: almk.karl@gmail.com
anamartins@unifeso.edu.br



VAGAS DE INICIAÇÃO CIENTÍFICA



LINHAS DE PESQUISA

- Montagem *de novo* de genomas de plantas nativas brasileiras
- Evolução por duplicação de genomas (WGD)
- Genômica comparativa e evolução
- Transcritômica em larga escala
- Genômica de bactérias promotoras de crescimento vegetal (PGPB)

REQUISITOS

- ✓ CR $\geq 7,5$
 - ✓ Inglês instrumental (leitura de artigos e documentação)
 - ✓ Interesse em programação e ciência de dados
- Não é exigida experiência prévia*

PERFIL QUE BUSCAMOS

- ♦ Autonomia e motivação para investigar problemas científicos e técnicos
- ♦ Organização e registro sistemático do trabalho
- ♦ Responsabilidade com prazos e presença nas reuniões do grupo

A iniciação científica no grupo é pensada como o início de uma trajetória em pesquisa, com perspectiva de publicação e continuidade na pós-graduação.

